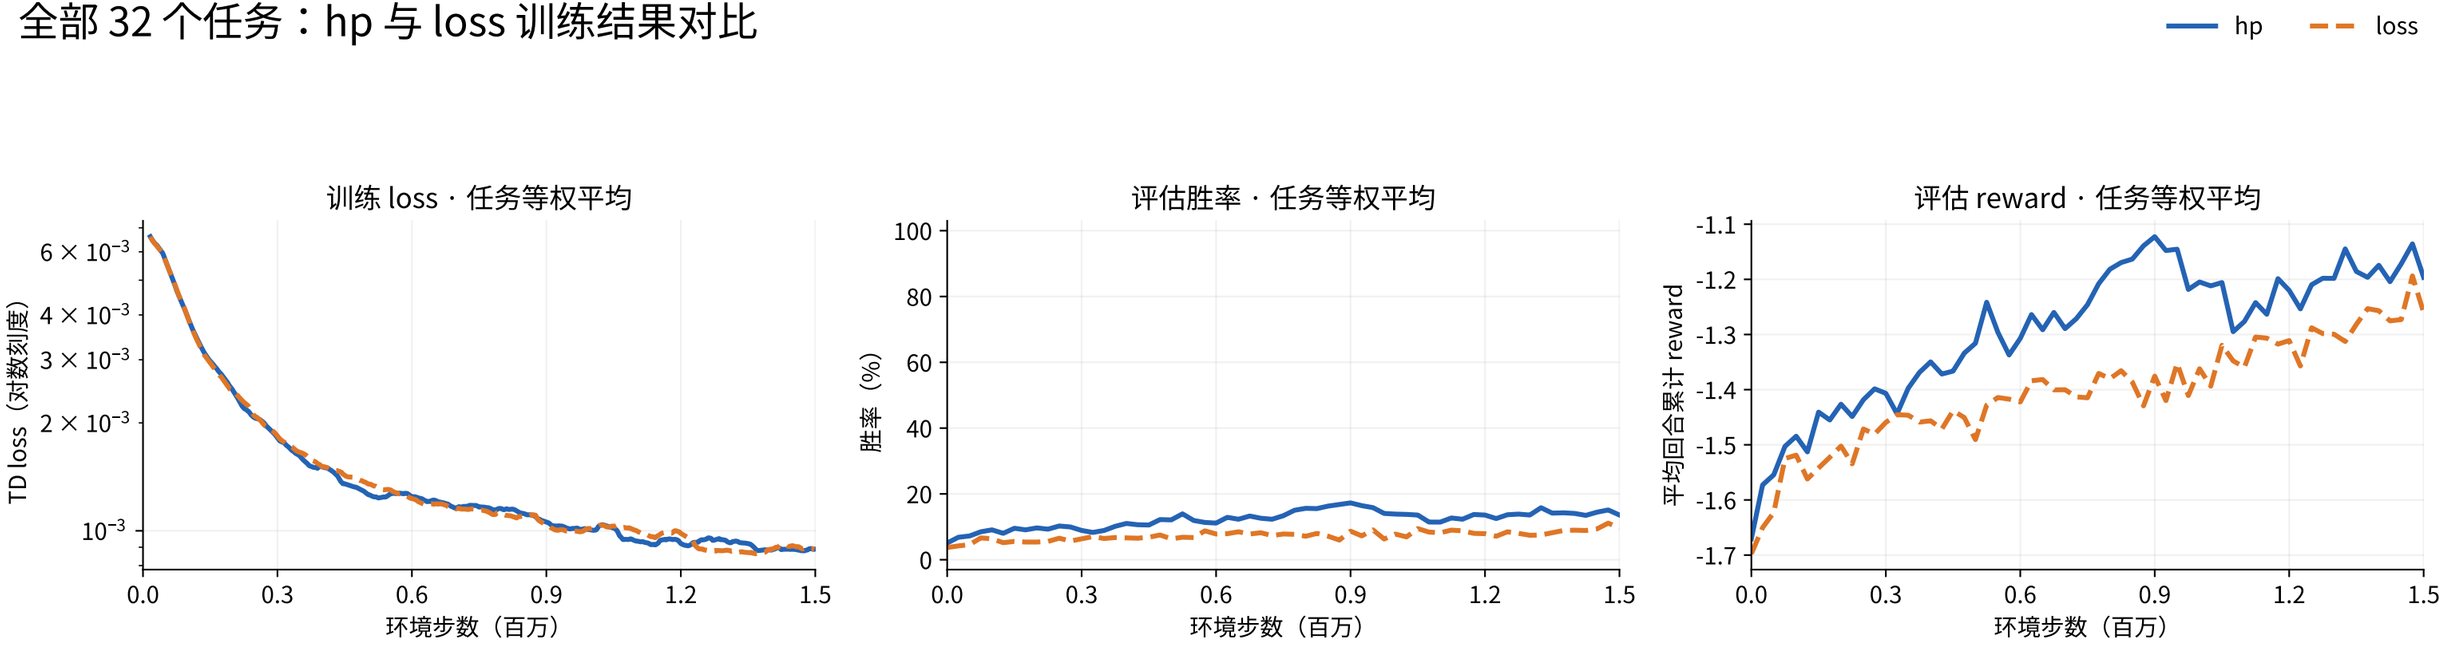
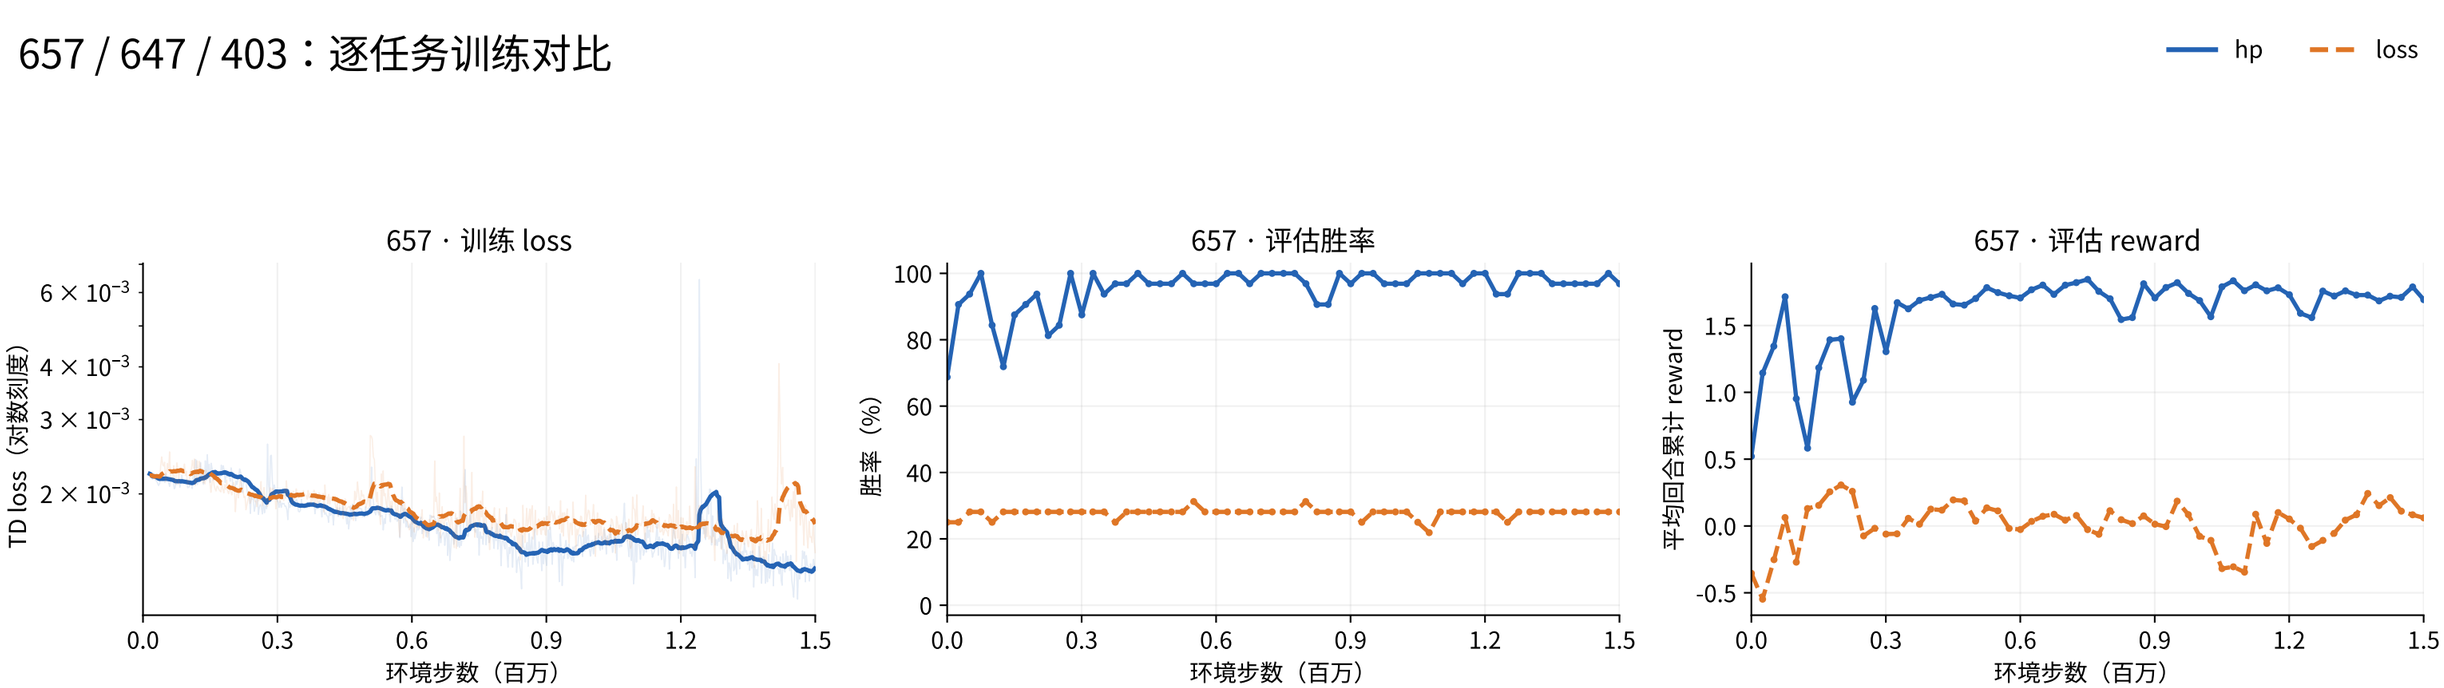
全部 32 个任务：hp 与 loss 训练结果对比



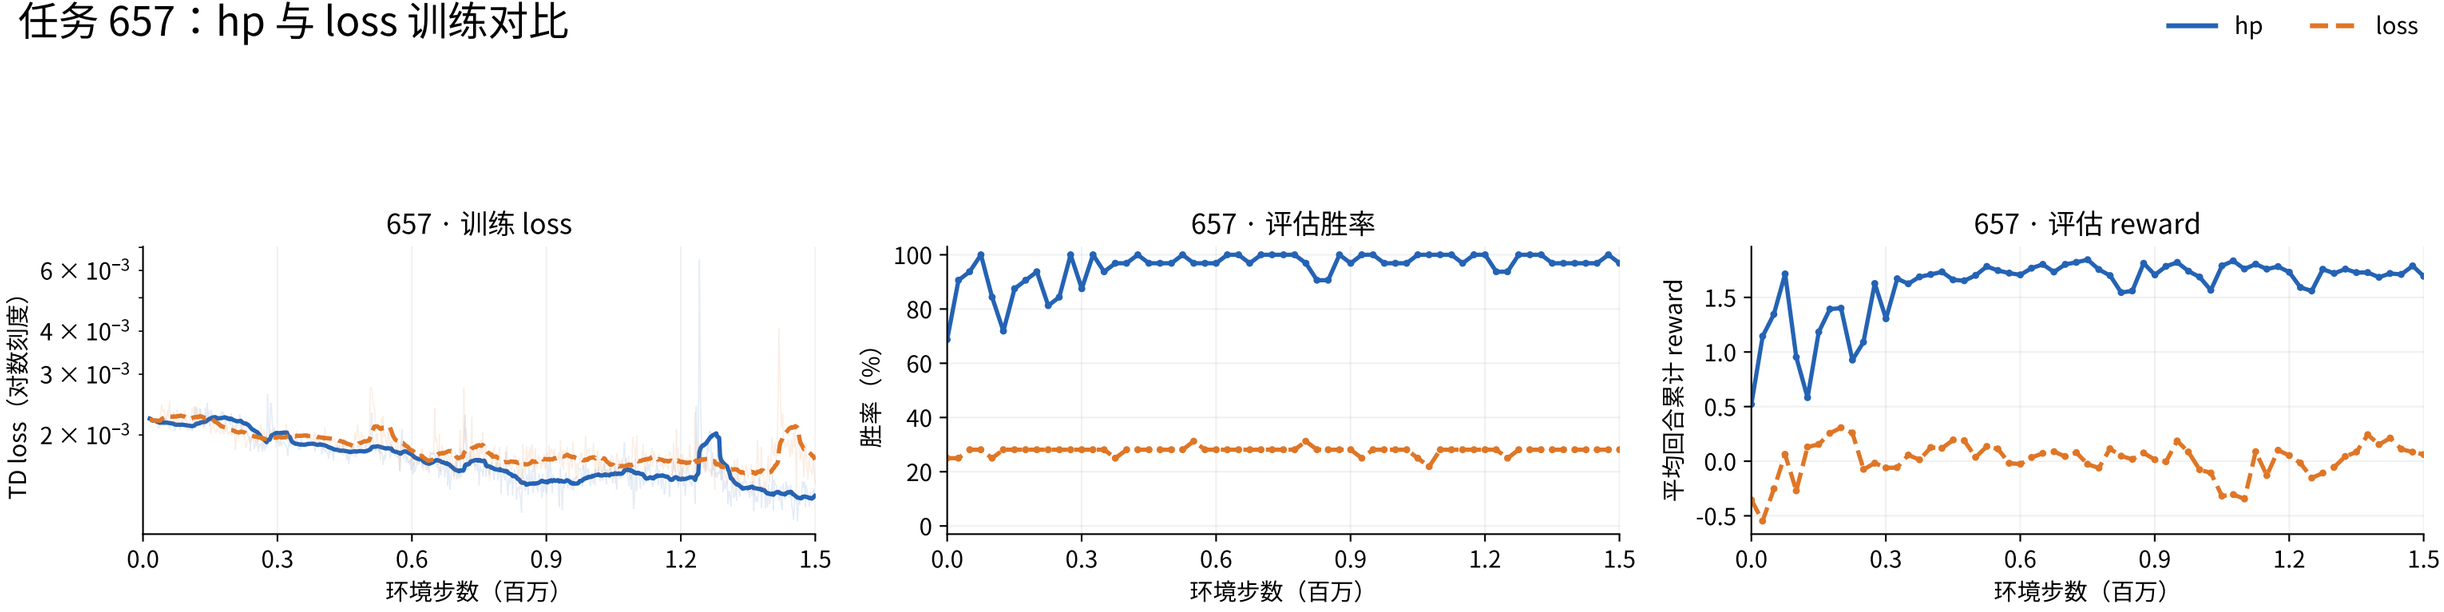
横轴为每个任务的训练进度；按环境步数插值对齐。loss 为 21 点后向均值；评估每点 32 局，单个训练 seed。

657 / 647 / 403：逐任务训练对比



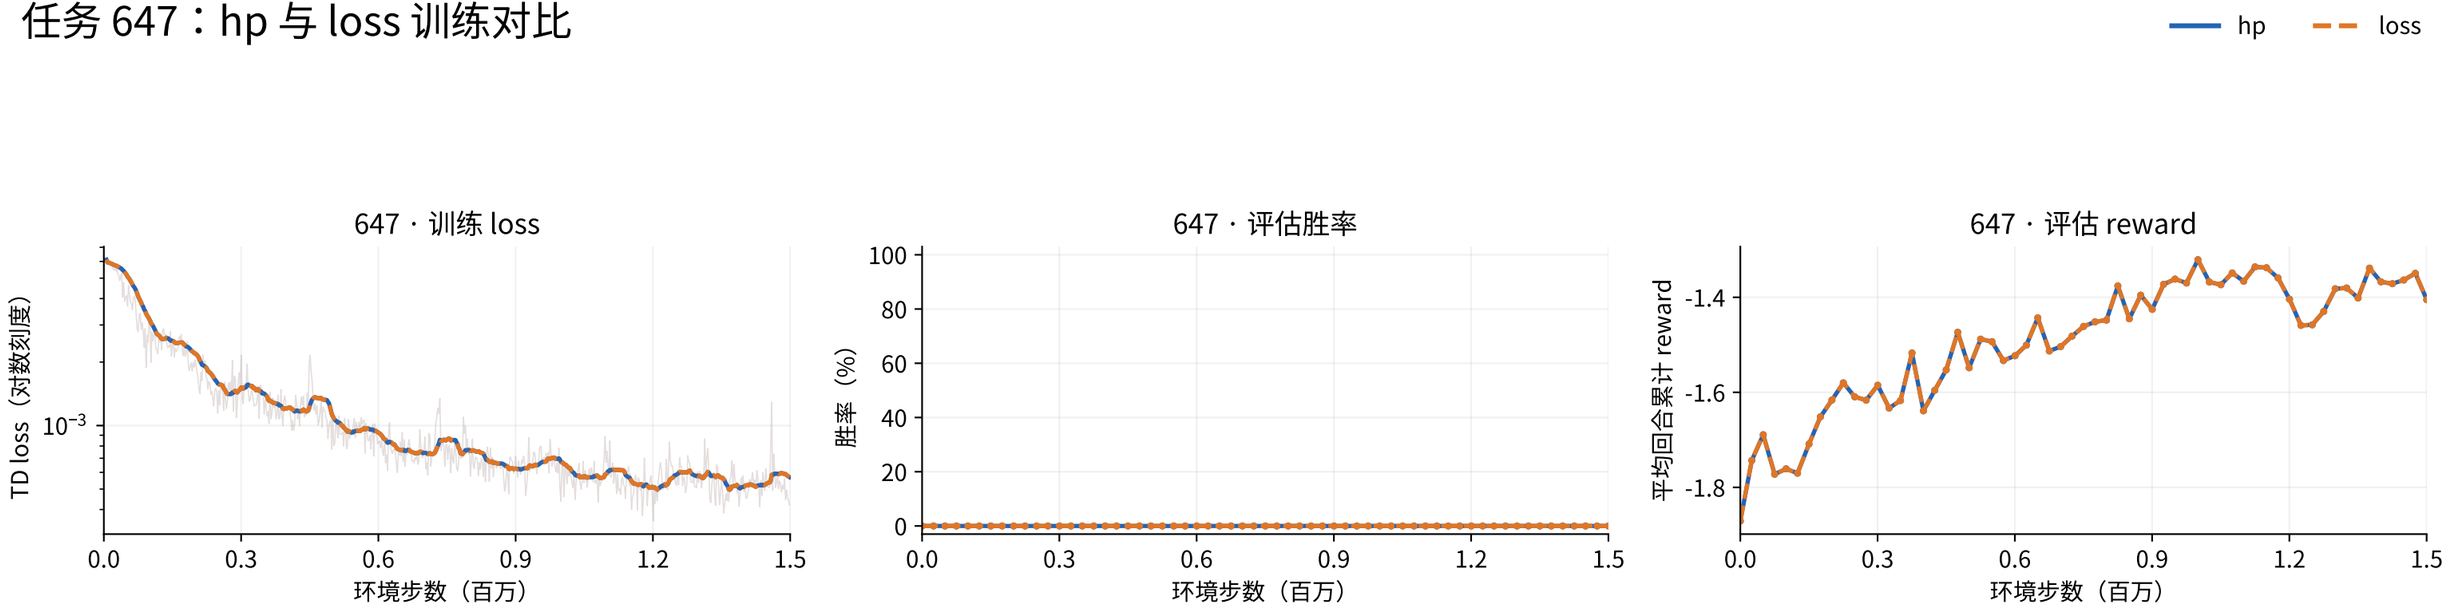
loss：浅线为原始值，粗线为 21 点后向均值。胜率 / reward：greedy 评估原始点（每点 32 局）。hp、loss 为两种超时判定规则。

任务 657：hp 与 loss 训练对比



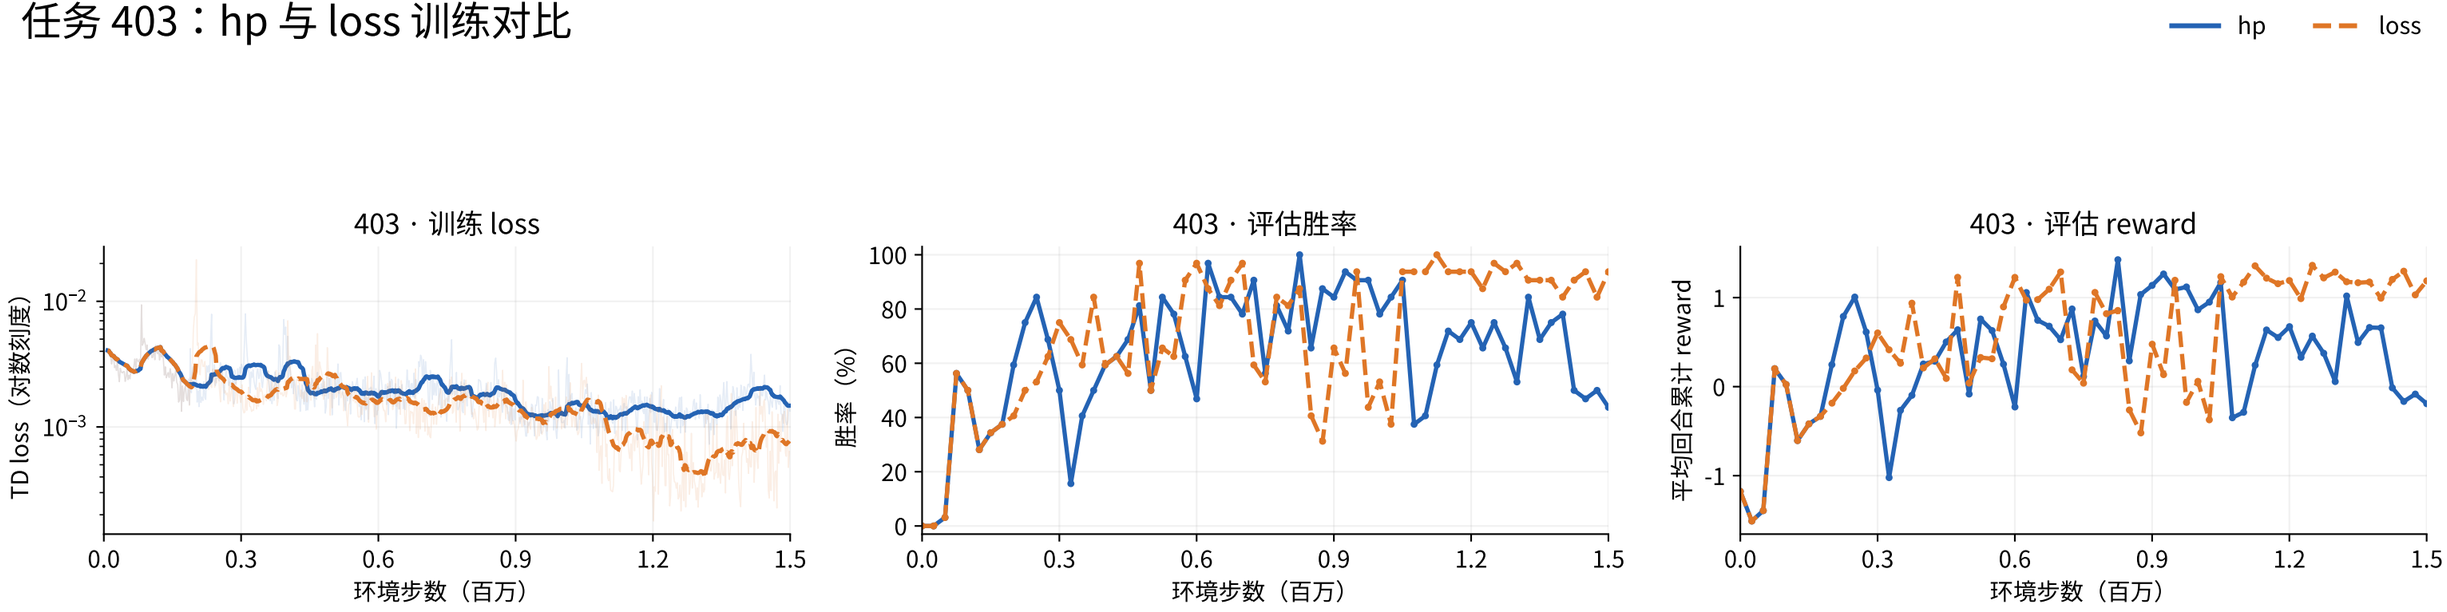
loss：浅线为原始值，粗线为 21 点后向均值。胜率 / reward：greedy 评估原始点（每点 32 局）。hp、loss 为两种超时判定规则。

任务 647：hp 与 loss 训练对比



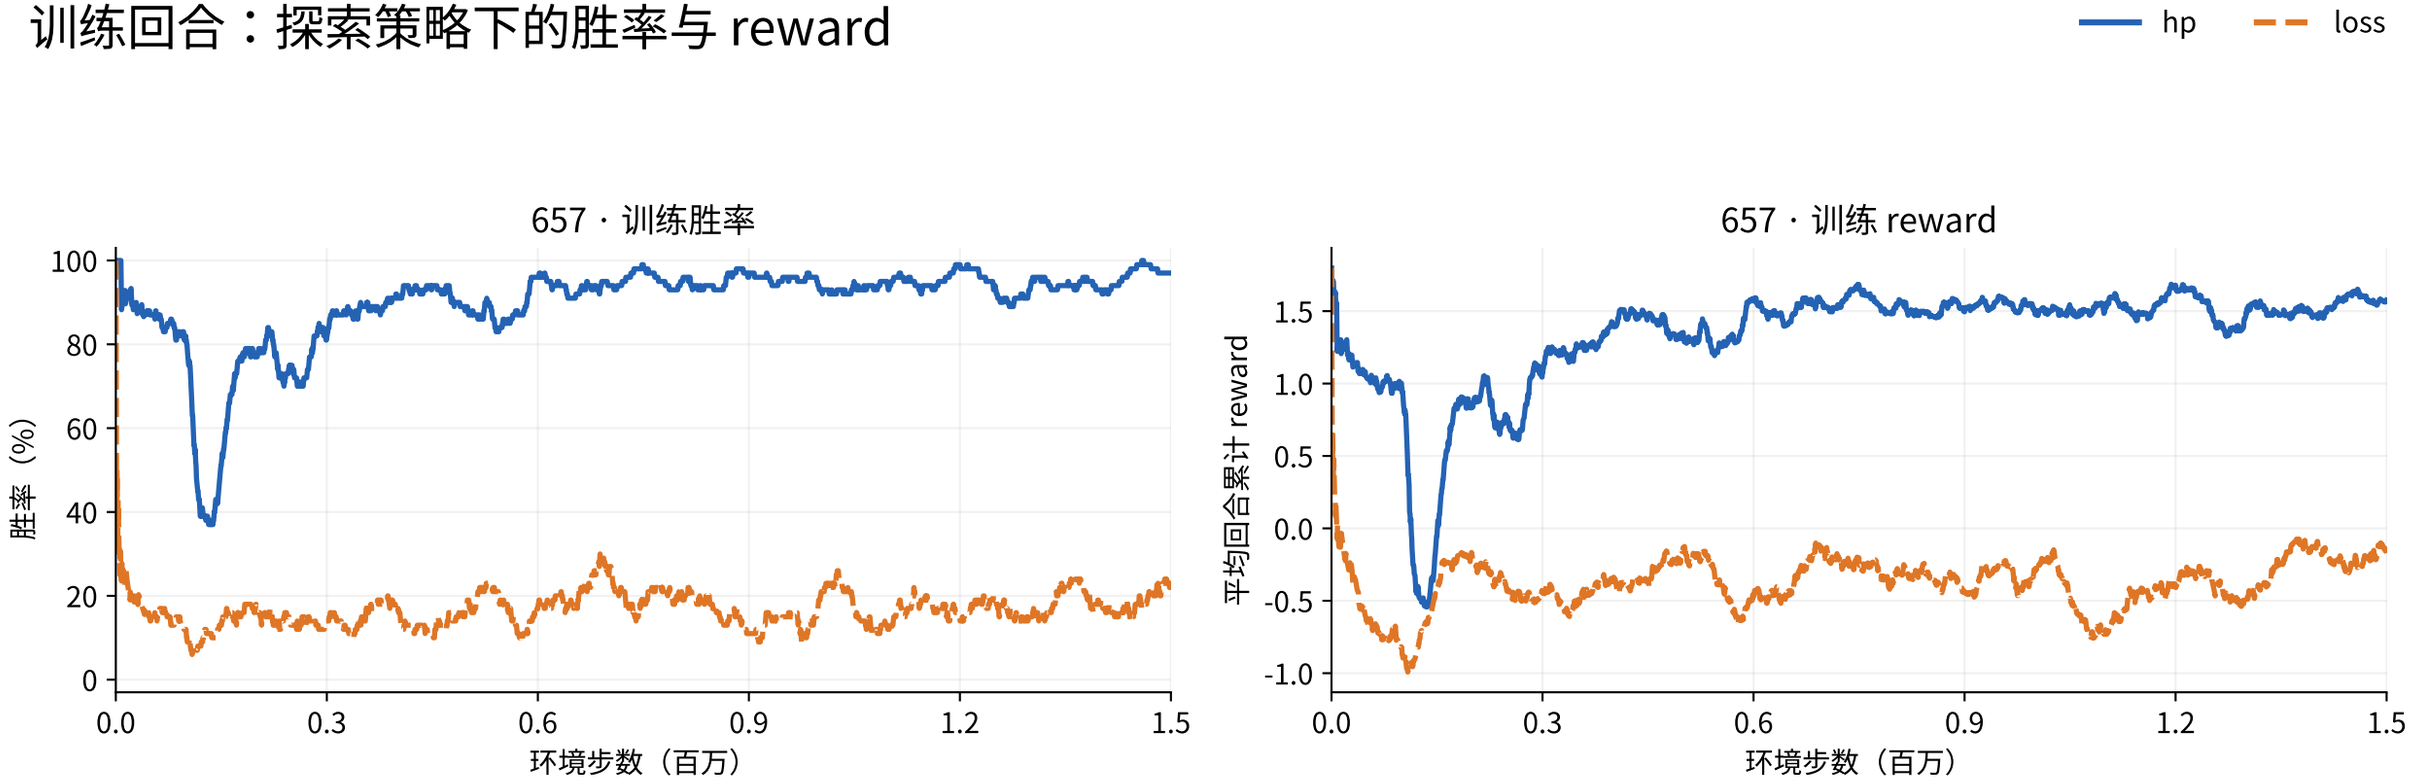
loss：浅线为原始值，粗线为 21 点后向均值。胜率 / reward：greedy 评估原始点（每点 32 局）。hp、loss 为两种超时判定规则。

任务 403：hp 与 loss 训练对比



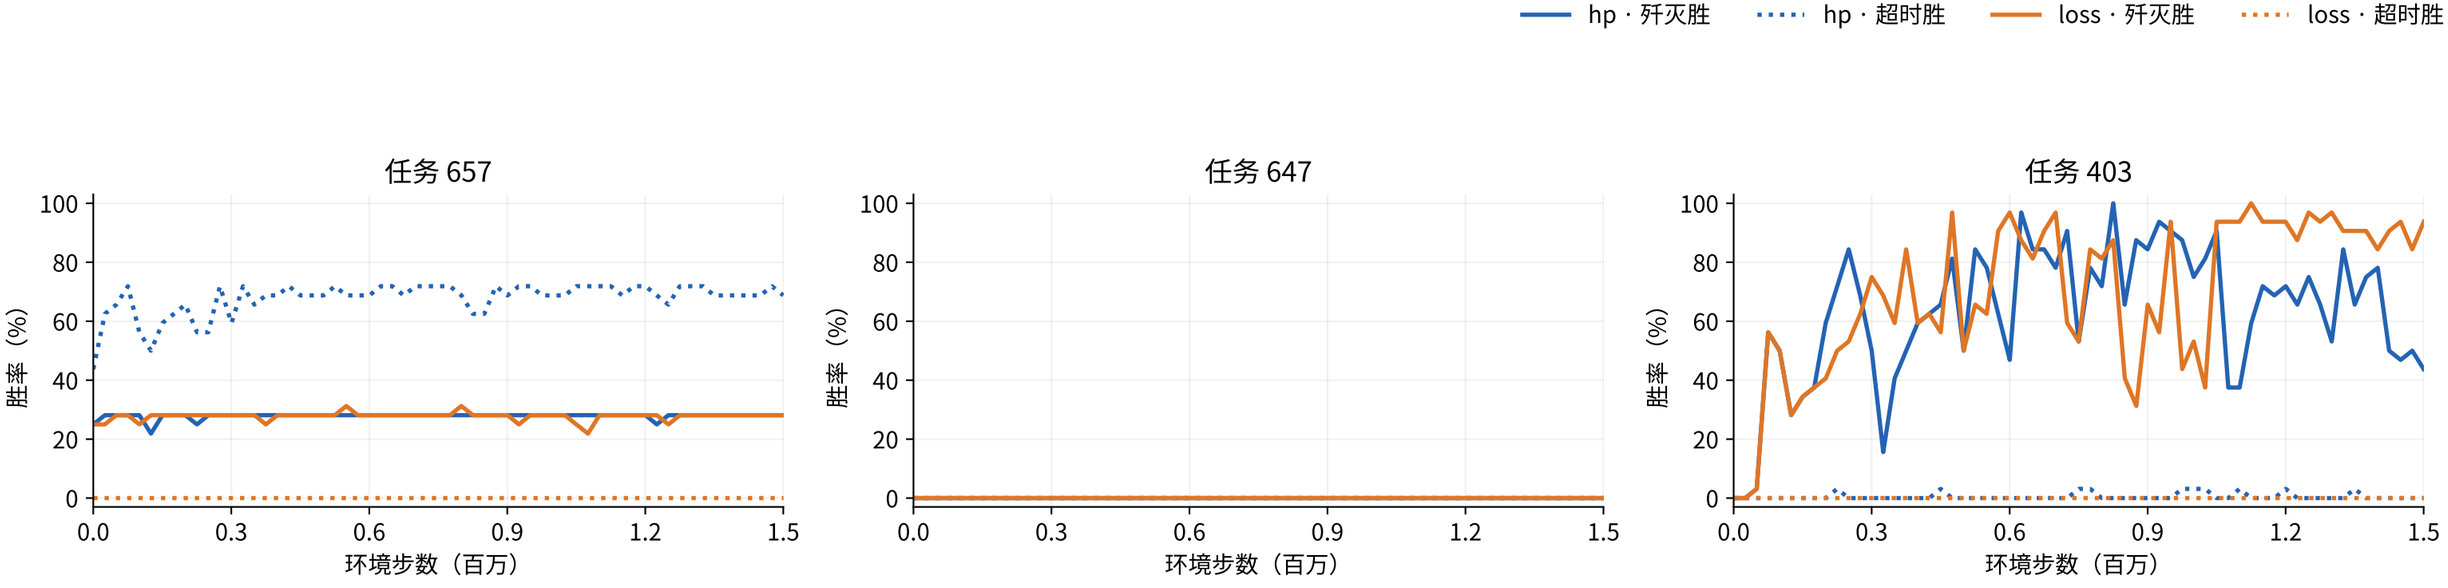
loss：浅线为原始值，粗线为 21 点后向均值。胜率 / reward：greedy 评估原始点（每点 32 局）。hp、loss 为两种超时判定规则。

训练回合：探索策略下的胜率与 reward



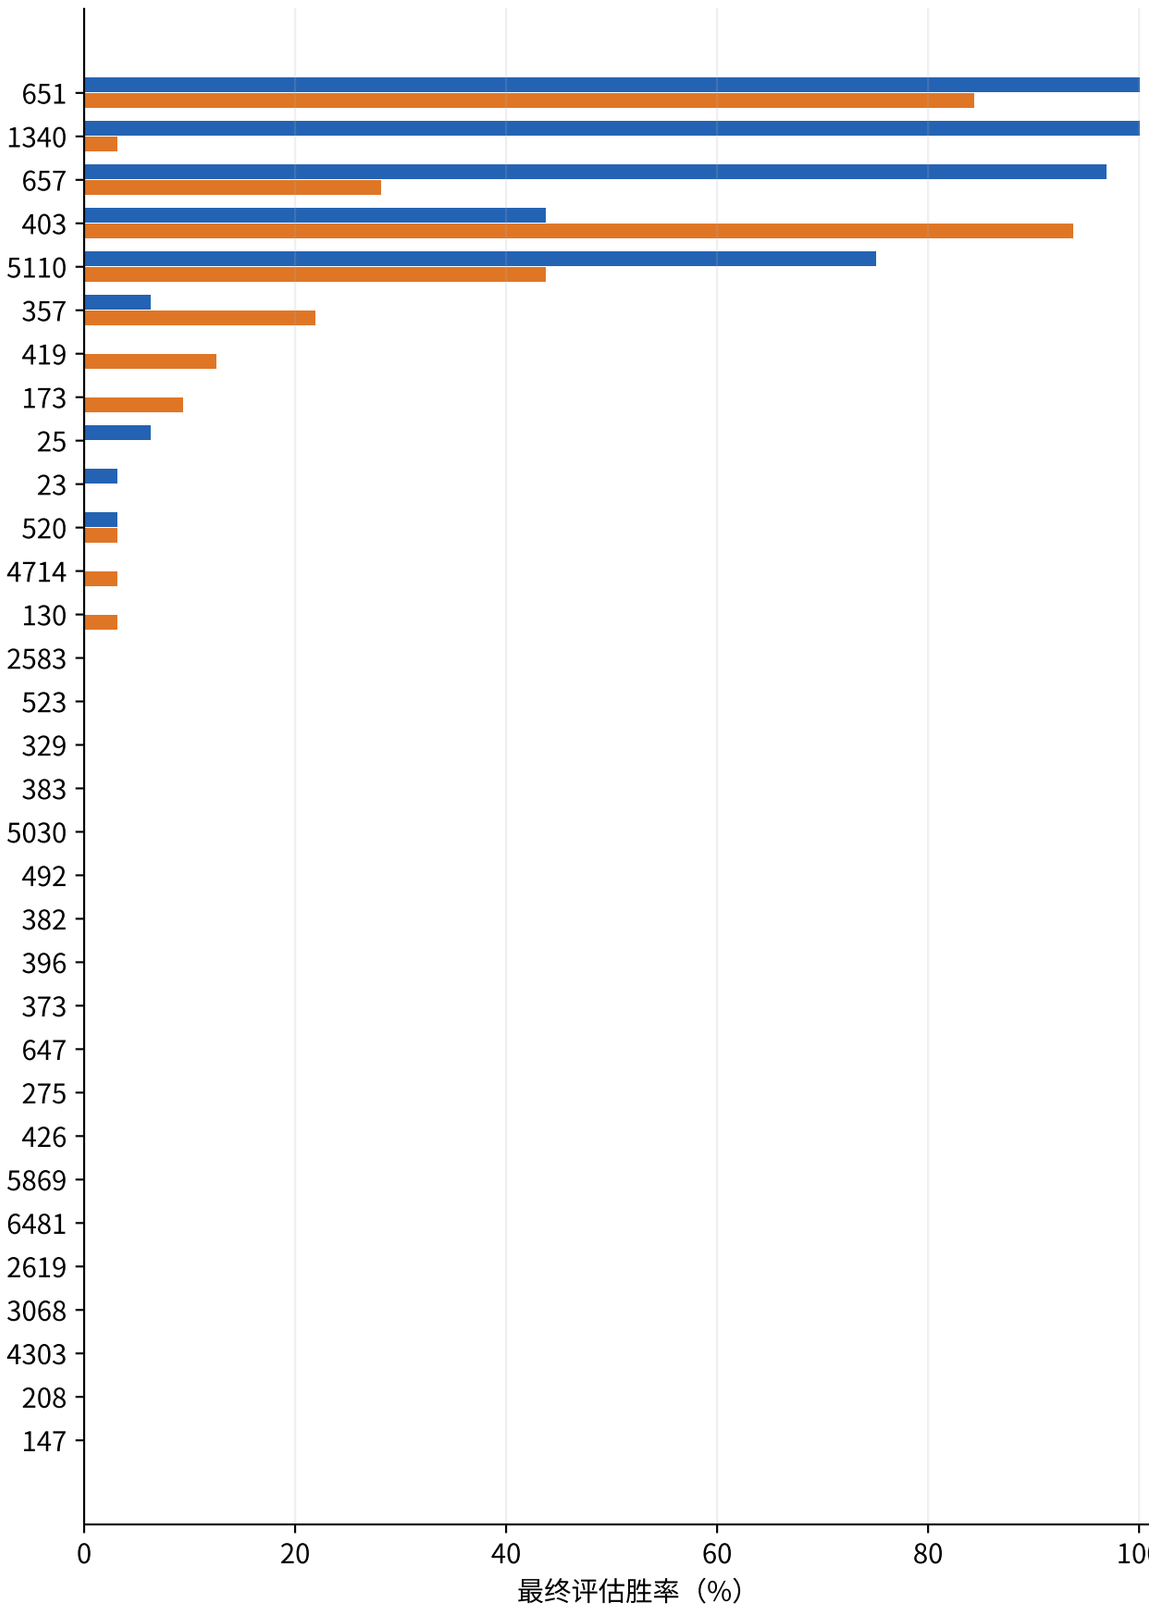
每条曲线为最近 100 个训练回合的后向均值；包含 epsilon-greedy 探索。训练回合与 greedy 评估分开显示。

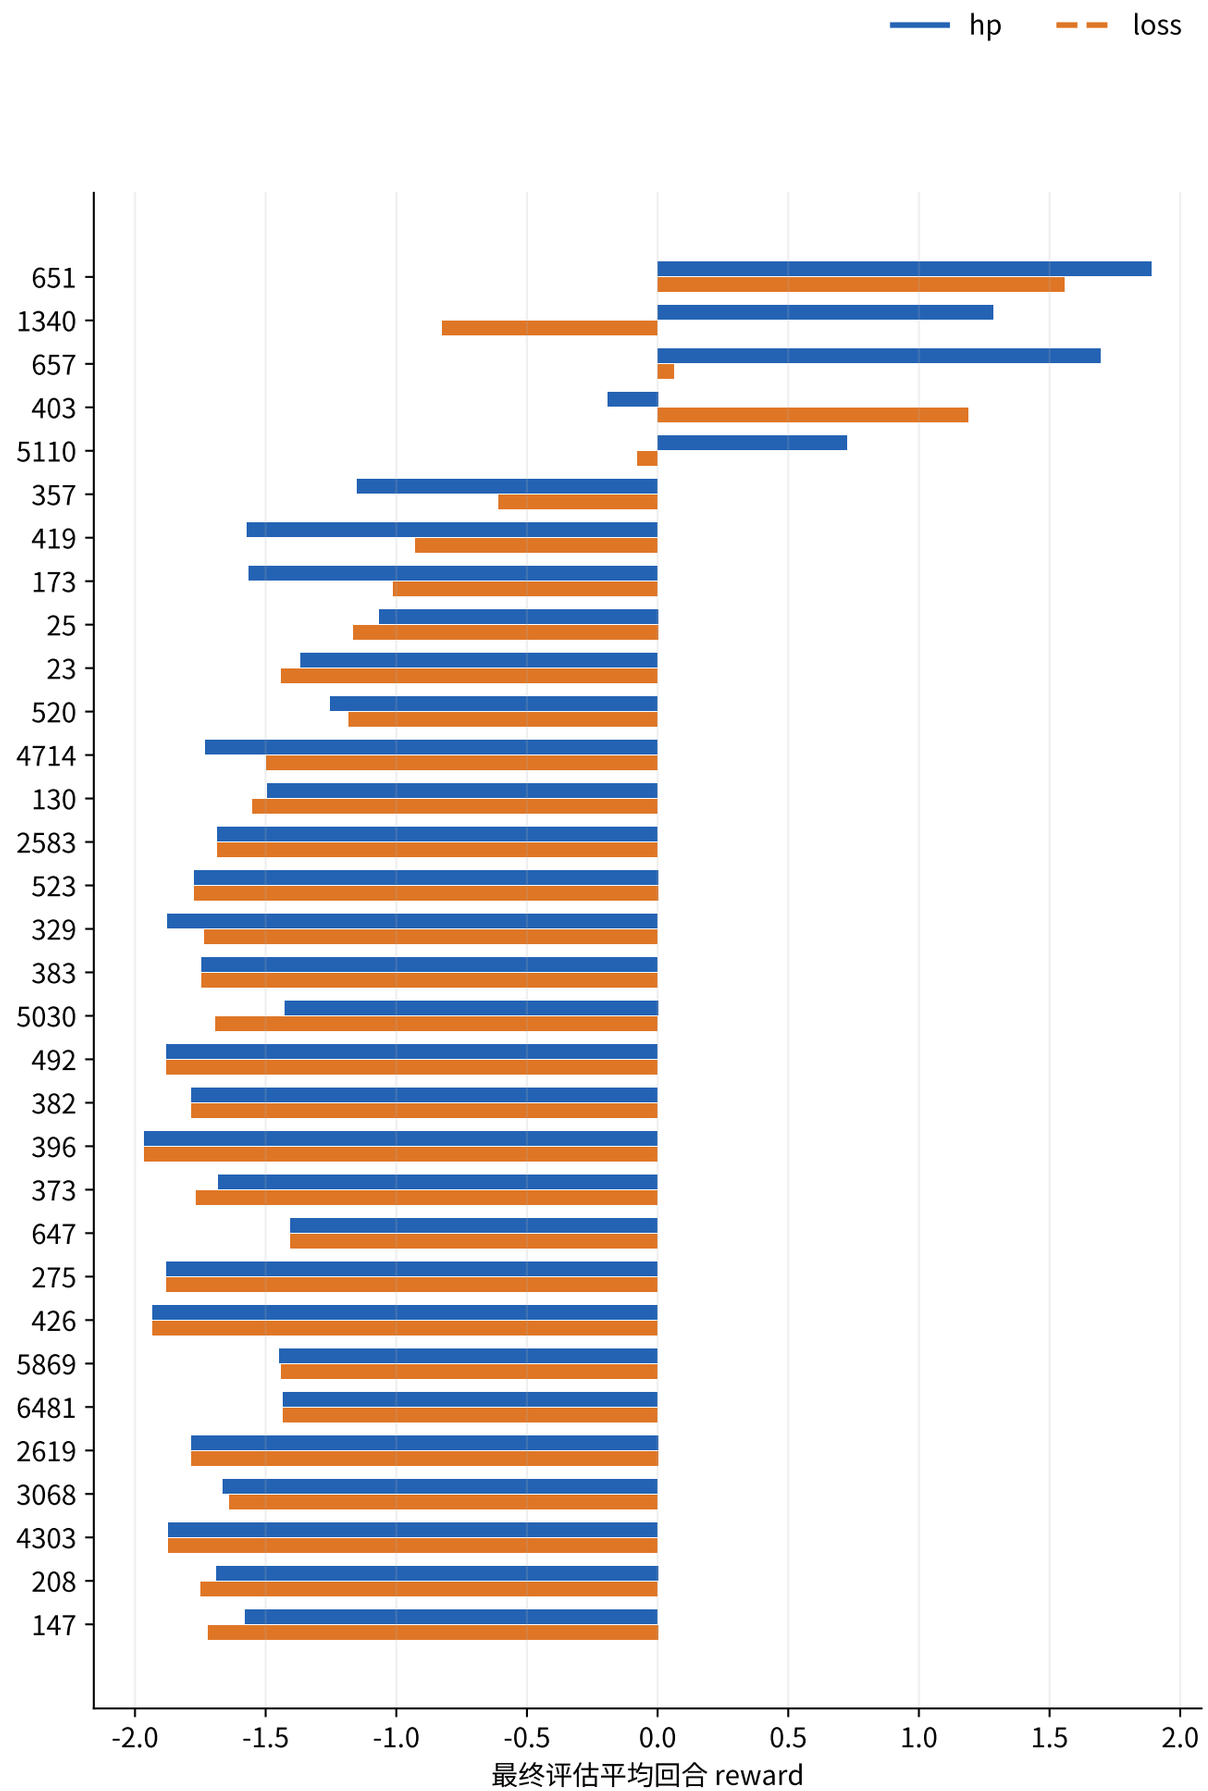
胜率来源：歼灭胜与超时胜



总胜率 = 歼灭胜率 + 超时胜率。hp 与 loss 使用各自的超时判定规则；相同颜色表示同一组。

全部 32 个任务：最终评估结果





最终 checkpoint 约为 150 万环境步；每任务每组评估 32 局，seed=1。